

$S_e^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n}$  *residuals*  $\sum (y_i - \hat{y}_i)^2$  a megfigyelt  $y$  és a becsült  $\hat{y}$  értékei közötti különbségek négyzetösszege.  $n-2$  szabadsági fokkal rendelkező mennyiség.  $\sum (y_i - \bar{y})^2$  a teljes variáció,  $\sum (\hat{y}_i - \bar{y})^2$  a regressziós variáció,  $\sum (y_i - \hat{y}_i)^2$  a maradék variáció.  $\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$

$COV(X, Y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N}$

$\sum (y_i - \hat{y}_i)^2 \rightarrow \min$   
 Normállegyenletek:  
 $\sum y_i = N \hat{\beta}_0 + \hat{\beta}_1 \sum x_i$   
 $\sum x_i y_i = \hat{\beta}_0 \sum x_i + \hat{\beta}_1 \sum x_i^2$   
 $\hat{\beta}_1 = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2 - \bar{x} \sum x_i}$   $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

**Kontraszt-hipotézis:** a dummy-2 együtthatókat és a referencia-együtthatót, illetve a különbségüket vizsgálja.  $\beta_0 + \beta_1 + 0 = \bar{y}_A$   
 $\beta_0 + 0 + \beta_2 = \bar{y}_B$   
 $\beta_0 - \beta_1 - \beta_2 = \bar{y}_C$

	$\beta_A$	$\beta_B$
A	1	0
B	0	1
C	-1	-1

$\beta_0 = \frac{\bar{y}_A + \bar{y}_B + \bar{y}_C}{3}$   
 $\beta_0$  a főátlag (ha azonos az exportár elemeinek, különben súlyozott átlag...)

**Referencia-hipotézis:** az együtthatók az elvártaként jelentkezők a ref. csoporttal (ami mindig a konstansra kerül).  $\beta_0 = \bar{y}_A$

	$\beta_A$	$\beta_B$
A	1	0
B	0	1
C	0	0

**Marginalis hatások:** a magy. vált.  $\hat{y}_i$  (egy egységnyi) átlagos hatására a válaszváltozó várható értéke mennyivel változik meg, ha az  $x_i$  egységnyi egységgel változik, a többi változó átlagosan konstans marad.

$SST = \sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$

Parciális kor.:  $y$  és  $x_i$  kapcsolatát vizsgálja, ha az összes többi magy. vált. hatását kiiktarítja.  $r_{y, x_i}^2 = \frac{SSR - SSR_{-i}}{SST - SSR_{-i}}$

$r_{y, x_i}^2 = \frac{-q_{yi}}{\sqrt{q_{yi} q_{ii}}}$ , ahol  $q_{ij} = R^{-1}_{ij}$

$R^2 = \frac{SSR}{SST} = 1 - \frac{1}{q_{yy}}$   
 $R^2 = \frac{\tau_{y1}^2 + \tau_{y2}^2 + \tau_{y3}^2}{1 - \tau_{11}^2 - \tau_{22}^2 - \tau_{33}^2}$

**Interakció:** az együtthatók közötti kölcsönhatás.  $\beta_{AB}$  az A és B együtthatók közötti interakció együtthatója.

$AIC = \frac{SSE}{n} e^{2(2+1)/n}$ ,  $BIC = \frac{SSE}{n} e^{(2+1)/n}$   
 $HQC = \frac{SSE}{n} (2n)^{2(2+1)/n}$

**Wald F-próba:**

$F = \frac{(SSR - SSR_u)/m}{SSR_u/(n-k-1)} = \frac{(R_u^2 - R^2)/m}{(1 - R^2)/(n-k-1)} \sim F(m, n-k-1)$

**LM-próba:** Lagrange-multiplikátor teszt.  $\chi^2(m)$  vagy  $\chi^2(n-k-1)$

**ANOVA/Globális F-próba 1. oldali:**  
 $F = \frac{SSR/k}{SSE/(n-k-1)} = \frac{R^2/k}{(1-R^2)/(n-k-1)} \sim F(k, n-k-1)$

**OLS torzítatlanság:**  $E(\hat{\beta}) = \beta$  Norm. eloszlású  
 $\sqrt{Var(\hat{\beta}_1)} = \frac{Se}{\sqrt{\sum (x_i - \bar{x})^2}}$   $N(\beta_1, Var(\hat{\beta}_1))$   
 $S_{\hat{\beta}_1} = \frac{Se}{\sqrt{\sum (x_i - \bar{x})^2}}$

**t-próba:**  
 $\frac{\hat{\beta}_1 - \beta_1}{S_{\hat{\beta}_1}} \sim t(n-k-1)$

readxl -> read\_excel  
 moments -> skewness, kurtosis  
 psych -> describe  
 Hmisc -> mean, sd, normal  
 gmodels -> cronbale, wilson  
 ggplot2 -> geom\_smooth, aes  
 ppcor -> pcor  
 corrr -> corrrplot

by (Practice[, 1:3]), Practice\$Cond, summary  
 prop.table(table(Town, Cond))  
 apply (Practice[, 1:3, 4]), quantile  
 qt, qnorm... -> invnorm  
 var.test, t.test (var.equal=F)  
 aov (Price ~ Cond, data=) -> rezeges  
 cov (Price ~ Cond, data=) -> kov. mtrix  
 cor -> kor. mtrix  
 pf, pt -> p-érték (F-nél: lower tail=F)  
 model.fitted.values -> becsült  $\hat{y}$   
 anova(model) [1,2,3] -> SSR, SSE  
 read.csv(2) -> read a 2. tábl  
 confint(model, level=0.95)

**OLS modellfeltételek:**

- 1) Nagy a minta (sz. FAE) vagy  $Y \sim N(\mu, \sigma^2)$
- 2) Linearitás  
 - A keresési valószínűség a feltételezett, azaz  $Y = X\beta + \epsilon$
- 3) Nincs szisztematikus hiba  
 -  $P(\text{rank } X = k+1) = 1$  (1 valószínűséggel teljes az orokosság)
- 4) Erős/szigorú exogenitás -> a hibák függetlenek a magy. vált. től  
 -  $E(\epsilon_i | X_i) = 0 \Rightarrow E(E(\epsilon_i | X_i)) = E(\epsilon_i) = 0$  és  $COV(X_i, \epsilon_i) = 0$   
 - Szigorúan érvelni, mint a korrelátlanság  
 - Van olyan változó, ami elnyelheti a magy. vált. hatást, de nem szerepel a modellben, miközben legalább egy magy. vált.-val korrelál (OVB) - confounding: egy változó csak azért korrelál egy másikkal, mert valójában egy vagy több másik változó hatását közvetíti, a magy. vált. től -> korreláció  $\neq$  kauzalitás  
 - Adottan hibák magy. vált.-nál (var. 20%)  
 - Simultaneitások (több változó modellje) -> kölcsönhatás  
 - Homoscedaszcitás (a hibák varianciája konstans)  
 -  $V(\epsilon_i) = 1, \dots, n: D^2(\epsilon_i | X) = \sigma^2$  (állandó) -> nagy különbség a magy. vált. között

- 5) Autokorrelátlanság  
 - A hibák közötti összefüggés a korrelátlanság egy-egy mátrix  
 - Ha a minta FAE, akkor automatikusan igaz  
 - Nem FAE ->  $COV(\epsilon_i, \epsilon_j | X) = 0$

4) és 5) együtt: a kovarianciamátrix  $\sigma^2 I$  alakú  
 Ha mindegyik modellfeltétel teljesül, akkor az OLS becslés BLUE:  
 Best (minimális varianciájú) 4) 5)  
 Linear (lineáris a mintaközvetlen) 1)  
 Unbiased (torzítatlan) 1) 2) 3)

Szisztematikus hiba

Magy. vált. hatása = közvetlen + közvetett  
 Parciális elasticitás: az  $x_i$  változó adott értékűre 1%-os változása hány %-os változással jár együtt az eredményváltozóban c.p.  
 $EL(\hat{y}_i, x_i) = \frac{\hat{\beta}_i x_i}{\hat{y}_i}$   
 $cor(y, \hat{y}) = R^2$  (okt. egyenlőség)  
 Egyenlőség: ha  $x$  és  $y$  közötti kapcsolat egyértelmű, akkor az  $R^2 = 1$



Log-Lin: Ha  $X_j$ -re egyéggel nagyobb, akkor  $e^{1.7}$ -szor nagyobb lesz  $y$  c.p. változása  
 Lin-Log:  $X_j$  1%-os változása változtatja  $y$ -t. egyéggel változtatja  $y$ -t.  
 Log-Log: Az  $X_j$ -ben előidéztett %-os változás,  $y$ -ban  $\beta_j$  százalékosan változtatja  $y$ -t.

Ramsey-Reset:  
 $\hat{y}_R = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon_1 \hat{y}^2 + \epsilon_2 \hat{y}^3 + \dots + \epsilon_k \hat{y}^k$   
 $H_0: \epsilon_1 = \epsilon_2 = \dots = \epsilon_k = 0$   
 F-próba vagy LM-próba

$y = \beta_0 + \beta_1 x_1 + \epsilon$   
 $y = \beta_{y0} + \beta_{y1} x_1 + \beta_{y2} x_2 + \epsilon$   
 $x_2 = \beta_{x0} + \beta_{x1} x_1 + \epsilon$   
 $\Rightarrow \beta_{y1} = \beta_{y1} + \beta_{x1} \beta_{y2}$   
 teljes körűen kóvetett

Multi-koll (nem egyértelmű):  
 1) Termékes jelenség, korreláció a változók között  
 2) Strukturális multi-koll: mi történik a modellben a jellel függvényformák (interakció, kvadrátikus függvény...)  
 $\Rightarrow$  A becslés torzítottan marad ( $E(\hat{\beta}_j) = \beta_j$ )  
 $\Rightarrow$  Nem lesz hatékony (és torzítottan becsülte körülmények között az a hatékonyabb, amelyiknek a varianciája a minimális, ha torzított, akkor  $MSE = Var(\hat{\theta}) + Bias^2(\hat{\theta})$  ( $Bias(\hat{\theta}) = E(\hat{\theta}) - \theta$ )  
 $\Rightarrow$  A nagy, változó körülmények közötti minél nagyobb  $Var(\hat{\beta}_j)$ , így nem hatékony  $\Rightarrow$  csökken a t-próba értéke  $\Rightarrow$  Nagyon a p-érték  
 $\Rightarrow$  Nem szignifikáns olyan volt, ami a multi-koll. nélkül az lenne

VIF( $\hat{\beta}$ ) =  $\frac{1}{1 - R^2_{X_j | X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_k}}$  = 33,46  $\Rightarrow$  A nagy változó paraméterének becsülési varianciája 33,46-szorosa a multi-koll. miatt  
 10 < ! A korrelációs mátrix inverzének fordítottjában a VIF-ek vannak!

Tol( $\hat{\beta}$ ) =  $1 - R^2_{\hat{\beta}} = (VIF(\hat{\beta}))^{-1} = 0,03 \Rightarrow$  A nagy változó körülmények közötti információs rendeltetés, amelyet a többi nagy volt nem tud magyarázni!  $! < \frac{1}{10}$

Főkomponensanalízis  $\Rightarrow$  0. Normalizálás az adatokhoz  
 $\Rightarrow R = C = \frac{1}{n} X^T X = B \Lambda B^T$  (Sajátértékprobléma, B unitár C szimmetrikus,  $\Lambda$  megfelelő sajátértékekkel)  $\Rightarrow X B$  főkomponensok  
 mátrix-a az  $\Lambda \Rightarrow$  Ezek az oszlopok a főkomponensek (varianciák egyenlő a sajátértékekkel)  $\Rightarrow$  Ezzel tartjuk meg, ahol  $\lambda = Var \geq 1$   
 Nem mindig kell mindezt normalizálni (Ezért az adatok ahol a korrel. 0,8)  
 Korrel. mátrix-el látjuk meg az  $\Lambda$  főkomponens (sajátértékprobléma)

Heteroszkedaszticitás  $\Rightarrow$  A hirtér  $D^2(E|X)$  nem állandó  
 $\Rightarrow$  Lehetőség: 1) Romb függvényforma 2) Proporzionált adatok (pl. háztartások) vizsgálatán (népességhez arányos) 3) Bővebb adatgyűjtés, háttér, fogymatikai modellek változtatása, stb.  
 $\Rightarrow$  Kövi: A becslés torzítottan marad ( $E(\hat{\beta}_j) = \beta_j$ )  
 A paraméterbecslés varianciája és a standard hiba torzított lesz és inkonzisztens  $\Rightarrow$  t-próba nem követ + elvileg, F nem követ + elvileg...  $\Rightarrow$  Nem megbízható a következtetés

White-teszt  $n R^2_{\epsilon^2 | X_1, \dots, X_k, X_1^2, \dots, X_k^2, X_1 X_2, \dots, X_{k-1} X_k}$   $\sim \chi^2(m)$   
 m a magyarázó változók száma ( $\beta_0$  NEH!)  
 $H_0: R^2 = 0 \Rightarrow$  Homoszkedaszticitás  
 BP:  $SSR \sim \chi^2(m) \Rightarrow$  Feltér, hogy a hiba  $\sim N(0, \sigma^2)$

Standard hiba  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  
 1) Standard hiba  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  
 2) GLS  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  $\Rightarrow$  A hirtér  
 $\beta = (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} y$ , ahol  $\Omega$  diag. mátrix, a diag. elemek a White-teszt segítségével becsült varianciák szorzata.  
 Logisztikus regr.  $y \in \{0, 1\} \Rightarrow P_x = P(y=1|X) \in [0, 1] \Rightarrow odds_x = \frac{P_x}{1-P_x} \in [0, \infty)$   
 $(P_x = \frac{odds_x}{1+odds_x}) \Rightarrow \logit_x = \ln(odds_x) \in (-\infty, \infty) = X\beta + \epsilon$   
 $\Rightarrow P_x = \frac{e^{X\beta}}{1+e^{X\beta}} \xrightarrow{ML} L = \prod_{i=1}^n P_{x_i}^{y_i} (1-P_{x_i})^{1-y_i} \Rightarrow \frac{\partial L}{\partial \beta} = \frac{e^{X\beta}}{1+e^{X\beta}} \rightarrow \max_{\beta}$

$P_i \Rightarrow$  Ha a saját bűné alapján 1%-os ponttal megadható, akkor várhatóan 4,52%-os alacsonyabb a valószínűség a c.p. ( $e^{0.0452} = 0,9548$ )  
 null deviance: az az a modell, ahol a log-likelihood  $= -n \ln p_0$   
 McFadden/Pseudo  $R^2$ : (null deviance - deviance) / null deviance  $\Rightarrow$  Milyen mértékben van a modellünk a strukturális modellhez / nullmodellhez

Helyes statisztika mindig (accuracy):  $\frac{TP+TN}{n}$   
 Szensitivitás (TPR):  $\frac{TP}{TP+FN}$   
 Specificitás (TNR):  $\frac{TN}{TN+FP}$   
 Az 1-es és 0-os találatok alapján az egyenlő valószínűséggel

$D^2[\hat{\beta}|X] = E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T | X] = E[(X^T X)^{-1} X^T (X\beta + \epsilon) - \beta] \cdot [(X^T X)^{-1} X^T (X\beta + \epsilon) - \beta]^T | X] = E[(\beta + (X^T X)^{-1} X^T \epsilon - \beta)(\beta + (X^T X)^{-1} X^T \epsilon - \beta)^T | X] = (X^T X)^{-1} X^T E[\epsilon \epsilon^T | X] X (X^T X)^{-1} = (X^T X)^{-1} X^T \sigma^2 I X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$   
 home. aut.  $\Rightarrow$  n elemű minta (FAE),  $\theta$  paraméter  
 MLE  $\rightarrow$   $L(y_1, \dots, y_n, \theta) = P(y_1 = z_1, \dots, y_n = z_n | \theta)$   
 Derivált:  $L(y_1, \dots, y_n, \theta) = \prod_{i=1}^n f(y_i | \theta) = \left(\frac{1}{\theta}\right)^n e^{-\frac{\sum x_i}{\theta}}$   
 Előfeltétel:  $L(y_1, \dots, y_n, \theta) = f(y_1, \dots, y_n | \theta)$

$f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$   $\theta > 0, x \geq 0$   $E\{x\} = \theta$   $D^2\{x\} = \theta^2$   
 n elemű FAE:  $L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i | \theta) = \left(\frac{1}{\theta}\right)^n e^{-\frac{\sum x_i}{\theta}}$   
 $\Rightarrow \ln L = -n \ln(\theta) - \sum x_i \cdot \frac{1}{\theta}$   $\frac{\partial}{\partial \theta} \ln L = -\frac{n}{\theta} + \frac{\sum x_i}{\theta^2} = 0 \Rightarrow$   
 $\Rightarrow \hat{\theta}_{MLE} = \frac{\sum x_i}{n} = \bar{x}$   $x_i \in [0, 1] \forall i \in \{1, \dots, n\}$   
 $f(x|p) = p^x (1-p)^{1-x} \Rightarrow L(x_1, \dots, x_n, p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$   
 $\Rightarrow \ln L = \sum x_i \ln p + (n - \sum x_i) \ln(1-p)$   $\frac{\partial}{\partial p} \ln L = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = 0 \Rightarrow$   
 $\Rightarrow (1-p) \sum x_i = p \sum (1-x_i) = 0 \Rightarrow \hat{p}_{MLE} = \frac{\sum x_i}{n}$  MASS számológép

lmtest  $\rightarrow$  resettest(model)  
 vcor  $\rightarrow$  vcovtest(model)  $\sim \beta$   $\sim$  kov. mátrix-e  
 corplot  $\rightarrow$  corplot(cov(data), method="color")  
 car  $\rightarrow$  vif(model)  $\sim$  diag(solve(cov(data)))  
 scale(data)  $\sim$  adatok normalizálása  
 eigen(cov(cov(scale(data))))  $\sim$  sajátértékek  
 psych  $\rightarrow$  describe(főkomponensek[, c("mean", "sd")])  
 prcomp(data, center=T, scale=T)  $\sim$  főkomponensanalízis  
 summary(focomp)  $\rightarrow$  főkomponensok  $X[, 1:3]$  a megmaradt adatok  
 abind(data, focomp[, 1:2])  
 broom  $\rightarrow$  glance(model)  
 stediastic  $\rightarrow$  white(model, interactions=T/F)  $\sim$  statisztika/p-érték  
 paste0(cnames(data[, 2:15]), "negyret")  
 lmtest  $\rightarrow$  bptest(model, studentize=T/F)  
 bs test(data, "pvalue")  
 car & lmtest  $\rightarrow$  coeftest(model, vcor = hccom(model))  $\sim$  korrigált SE-ek  
 nlme  $\rightarrow$  gls(formula, data)

glm(formula, data, family=binomial(link="logit"))  $\sim$  logit modell  
 summary(model)\$null.deviance / deviance  $\sim$  McFadden-teszt  
 pROC  $\rightarrow$  roc(data\$pred, model\$fitted.values)  
 plot(ROC, col="red", main="Cred. modell ROC görbe", xlim=c(1,0), ylim=c(0,1), type="l")  
 pROC  $\rightarrow$  auc(ROC)

predict(logitmodel, data)  $\sim$  logit értékek  $\Rightarrow$  a válasz  $\Rightarrow$  type="response"  
 paraméterrel  $P$ - $\beta$   $\sim$  a válasz  
 crosstabs  $\rightarrow$  crosstabs > 0.5 = crosstabs  $\rightarrow$  table(csd\$csod, csd\$beslos)  
 pROC  $\rightarrow$  coords(ROCcurve, "best", ret="threshold", best.method="closest.to left", youden")  $\sim$  cut value youden  
 DescTools  $\rightarrow$  PseudoR2(logitmodel, "McFadden")



WN  $\approx$  FAE  
 autocorr.  $\phi$  (gyenge)  $\sigma^2$   
 $\forall t=0, \dots, T: E(y_t) = \mu, \text{Var}(y_t) = \sigma^2$   
 $\forall 270: ACF(2) = PACF(2) = 0$   
 set.seed(10)  
 rnorm(dob,  $\mu$ ,  $\sigma$ )  
 runif(dob, a, b)  
 Proba 2 WN-ra:  
 → Durbin-Watson  
 • 1. vizsgálat elrendelt autokorr. tesztelésére  
 •  $H_0$ : nincs elrendelt autokorr.  
 • Ha a probafo. 1,8-2,2 közé esik, akkor  
 vizsgálódan  $\phi$  elrendelt autokorr.  
 •  $\text{Lmtest} \rightarrow \text{dwtest}(df \sim 1, \text{alternative} = \text{"two.sided"})$   
 → Ljung-Box (jóbban  $H_0$  mellett)  
 •  $H_0: \rho_1 = \rho_2 = \dots = \rho_p = 0$  (p lagig autokorrreláció)  
 •  $H_1: \exists j \in \{1, \dots, p\}: \rho_j \neq 0$   
 • Probafo.:  $Q^* = T(T+2) \sum_{j=1}^p \frac{\hat{\rho}^2(j)}{T-j} \sim_{H_0} \chi^2(p-b)$   
 (b a becsült paraméterek száma  $\Rightarrow$  d'et. 0)  
 • Box.test(df, lag=10, type="Ljung-Box")  
 → Breusch-Godfrey  
 • Szegregresszió  $\Rightarrow$  LM teszt ( $\sim \chi^2$  elrendelt  $H_0$  esetén)  
 •  $y_t = \alpha + \sum_{j=1}^p \phi_j y_{t-j}, H_0: \phi_1 = \phi_2 = \dots = \phi_p = 0$   
 •  $\text{Lmtest} \rightarrow \text{bptest}(df \sim 1, \text{order} = p)$

WN  $\Rightarrow$  korrelációs  $\Rightarrow$   $\text{fct} \rightarrow \text{fct} \rightarrow \text{fct}$   
 $\text{Lmtest} \rightarrow \text{coef} \rightarrow \text{model}$   
 $\cdot$  2-proba ( $\mu$  i. HL becsülés)  
 $\text{anima}(df, \text{order} = c(p, i, q))$   
 $\text{anima.sim}(\text{list}(ar = \dots), n = 500)$   
 (egyéb ts)  
 $\text{tseries} \rightarrow \text{jarque.bera.test}(\text{resid}(\text{model}))$   
 ( $H_0$ : normalis)  
 $\text{qnorm}(\text{resid}(\text{model}))$   
 $\text{qqline}(\text{resid}(\text{model}))$   
 $\text{plot}(\text{predict}(\text{model}), \text{main} = \text{"Ljung-Box"}, \text{ylim} = c(-10, 10))$   
 In sample elrendelt  
 $\text{plot}(df)$   
 $\text{lines}(\text{fitted}(\text{model}))$   
 Out-of-sample elrendelt  
 $\text{predict}(\text{model}, \text{n.ahead} = 15)$   
 $\text{ts.plot}(df, \text{pred} = \text{pred}, \text{lty} = c(1, 3), \text{col} = c(5, 2))$   
 Csak rövid távú előrejelzésre jó!  
 (gyakorlatilag  $E(y_t) = \mu$ )  
 Ha AR(3)  $\Rightarrow$  AR(1) és AR(2) is  
 Ha MA(1)  $\Rightarrow$  nem pontos elrendelt  
 AR-22  
 ACF, PACF standard hiba  $1/\sqrt{n} \sim N$   
 RWDP:  $y_t = y_{t-1} + c + u_t \sim y_t = c \cdot t + u_t$   
 ADF:  $\Delta y_t = \alpha + \delta_1 y_{t-1} + \sum_{i=2}^p \delta_i y_{t-i} + u_t$   
 $H_0: \phi_1 = 1 \Leftrightarrow \delta_1 = 0$   
 RW folyamatos differenciálás  
 $\text{tseries} \rightarrow \text{adf.test}$   
 Main:  $\text{Ljung-Box}$  teszt  $H_0$ : stacioner  
 $\text{urca} \rightarrow \text{urdf}$  PP. teszt  $H_0$ : nem stac.  
 $\text{FinTS} \rightarrow \text{ArchTest}(df, \text{lags} = 12)$

AR(p) folyamatos  $\rightarrow$  ACF lágeng, PACF p lag után elrendelt  
 $y_t = \delta + \sum_{j=1}^p \phi_j y_{t-j} + u_t, u_t \sim \text{NWN}(0, \sigma^2)$   
 $E(y_t) = E(\delta + \sum_{j=1}^p \phi_j y_{t-j} + u_t) = \delta + E(y_t) \cdot \sum_{j=1}^p \phi_j$   
 $\text{Var}(y_t) = \text{Var}(\delta + \sum_{j=1}^p \phi_j y_{t-j} + u_t) = \text{Var}(\delta + \sum_{j=1}^p \phi_j y_{t-j}) + \sigma^2$   
 $\Rightarrow \text{AR}(1)\text{-re}: ACF(2) = \phi_1^2, \text{Var}(y_t) = \frac{\sigma^2}{1 - \phi_1^2}$   
 $\text{AR}(2)\text{-re}: ACF(1) = \frac{\phi_1}{1 - \phi_2}, ACF(2) = \frac{\phi_2}{1 - \phi_2} + \phi_2, ACF(3) = \phi_1 \cdot ACF(2-1) + \phi_2 \cdot ACF(2-2)$   
 $\text{ARMA}(p, q)$   
 $y_t = \delta + \sum_{j=1}^p \phi_j y_{t-j} + \sum_{j=1}^q \theta_j u_{t-j} + u_t$   
 $E(y_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j}) + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j})$   
 $\text{ARMA}(1, 1):$   
 $\text{Var}(y_t) = \sigma^2 \cdot \frac{1 + 2\phi_1\theta_1 + \theta_1^2}{1 - \phi_1^2}$   
 $ACF(1) = \frac{(\phi_1 + \theta_1)(1 + \phi_1\theta_1)}{1 + 2\phi_1\theta_1 + \theta_1^2}$   
 $ACF(2) = \phi_1 \cdot ACF(2-1)$   
 $\text{Var}(y_t) = \frac{1 - \phi_2}{1 - \phi_2} \cdot \sigma^2$

MA(q) folyamatos  $\rightarrow$  ACF q lagig teszt 0-ig, PACF lágeng  
 $y_t = \delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t, u_t \sim \text{NWN}(0, \sigma^2)$   
 $E(y_t) = \delta + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta$   
 $\text{Var}(y_t) = \text{Var}(\delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t) = \text{Var}(\sum_{j=1}^q \theta_j u_{t-j} + u_t) = \sum_{j=1}^q \theta_j^2 \sigma^2 + \sigma^2$   
 $\text{ARMA}(p, q)$   
 $y_t = \delta + \sum_{j=1}^p \phi_j y_{t-j} + \sum_{j=1}^q \theta_j u_{t-j} + u_t$   
 $E(y_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j}) + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j})$   
 $\text{ARMA}(1, 1):$   
 $\text{Var}(y_t) = \sigma^2 \cdot \frac{1 + 2\phi_1\theta_1 + \theta_1^2}{1 - \phi_1^2}$   
 $ACF(1) = \frac{(\phi_1 + \theta_1)(1 + \phi_1\theta_1)}{1 + 2\phi_1\theta_1 + \theta_1^2}$   
 $ACF(2) = \phi_1 \cdot ACF(2-1)$   
 $\text{Var}(y_t) = \frac{1 - \phi_2}{1 - \phi_2} \cdot \sigma^2$

MA(q) folyamatos  $\rightarrow$  ACF q lagig teszt 0-ig, PACF lágeng  
 $y_t = \delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t, u_t \sim \text{NWN}(0, \sigma^2)$   
 $E(y_t) = \delta + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta$   
 $\text{Var}(y_t) = \text{Var}(\delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t) = \text{Var}(\sum_{j=1}^q \theta_j u_{t-j} + u_t) = \sum_{j=1}^q \theta_j^2 \sigma^2 + \sigma^2$   
 $\text{ARMA}(p, q)$   
 $y_t = \delta + \sum_{j=1}^p \phi_j y_{t-j} + \sum_{j=1}^q \theta_j u_{t-j} + u_t$   
 $E(y_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j}) + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j})$   
 $\text{ARMA}(1, 1):$   
 $\text{Var}(y_t) = \sigma^2 \cdot \frac{1 + 2\phi_1\theta_1 + \theta_1^2}{1 - \phi_1^2}$   
 $ACF(1) = \frac{(\phi_1 + \theta_1)(1 + \phi_1\theta_1)}{1 + 2\phi_1\theta_1 + \theta_1^2}$   
 $ACF(2) = \phi_1 \cdot ACF(2-1)$   
 $\text{Var}(y_t) = \frac{1 - \phi_2}{1 - \phi_2} \cdot \sigma^2$

MA(q) folyamatos  $\rightarrow$  ACF q lagig teszt 0-ig, PACF lágeng  
 $y_t = \delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t, u_t \sim \text{NWN}(0, \sigma^2)$   
 $E(y_t) = \delta + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta$   
 $\text{Var}(y_t) = \text{Var}(\delta + \sum_{j=1}^q \theta_j u_{t-j} + u_t) = \text{Var}(\sum_{j=1}^q \theta_j u_{t-j} + u_t) = \sum_{j=1}^q \theta_j^2 \sigma^2 + \sigma^2$   
 $\text{ARMA}(p, q)$   
 $y_t = \delta + \sum_{j=1}^p \phi_j y_{t-j} + \sum_{j=1}^q \theta_j u_{t-j} + u_t$   
 $E(y_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j}) + \sum_{j=1}^q \theta_j E(u_{t-j}) + E(u_t) = \delta + \sum_{j=1}^p \phi_j E(y_{t-j})$   
 $\text{ARMA}(1, 1):$   
 $\text{Var}(y_t) = \sigma^2 \cdot \frac{1 + 2\phi_1\theta_1 + \theta_1^2}{1 - \phi_1^2}$   
 $ACF(1) = \frac{(\phi_1 + \theta_1)(1 + \phi_1\theta_1)}{1 + 2\phi_1\theta_1 + \theta_1^2}$   
 $ACF(2) = \phi_1 \cdot ACF(2-1)$   
 $\text{Var}(y_t) = \frac{1 - \phi_2}{1 - \phi_2} \cdot \sigma^2$



weirdays(df\$date) readxl → read\_excel() LOESS: Locally estimated scatterplot smoothing  
 months(df\$date) A megfigyelés adott időpontjában (span) környékében minimalizálja a  
 quarters(df\$date) hibát, illetve az egységet, és ebből kapunk egy simított trendet a  
 relevel(df\$quarter, ref="Q4") teljes időszorra.  
 cor(), pcor → pcorr(), acf(), pacf(), loess(celvalt, ~t, data=df, span=0.4)

Exp trend → log-lin (értelmezés:  $e^{\beta_0 + \beta_1 t}$  - azaz velt.) STL: Seasonal and Trend Decomp. using  
 ↳ hibát  $y_t / \hat{y}_t$  vagy  $\exp(\text{hibát})$  Trend-Season-2aj Loess  
 Resid.-szám:  $se = \sqrt{\frac{SSE}{T}}$  (decompose-ből add és multi. esetben is megmarad a season. a

Additív modellben a seasonális eltérés megmutatja, hogy az adott időszakra átlagosan mennyivel tér el a trendtől / kiértékelést ⇒ Kontraszt-értékek!  
 Kontraszt-értékek

\* contrasts(df\$napok) (most) A 1. és 2. csoport közötti különbség (B a ref.)  
 contr.sum(Z) (arásm) B 0 1  $\beta_0 + 0 + \beta_B = \bar{y}_B$   
 kontr.mtx = contr.sum(Z) C -1 -1  $\beta_0 - \beta_C - \beta_D = \bar{y}_C$   
 rownames(kontr.mtx) = rownames(contrasts(df\$napok))  
 colnames(kontr.mtx) = C (felvétel a \* szimmetria)

A 3. csoport a többi 2-vel szemben (B a ref.)  
 Dummy-nál:  $D_A = GMA - GM_B = GMA - \beta_0$  (B a ref.)  $M = \text{mean}(\text{dummy})$   
 Kontr.-nál:  $C_A = GMA - M$ ,  $C_B = GM_B - M$  (GM-Group Mean)  

$$\beta_0 + \beta_{C_A} + 0 = \bar{y}_A$$
  

$$\beta_0 + 0 + \beta_{C_B} = \bar{y}_B$$
  

$$\beta_0 - \beta_{C_A} - \beta_{C_B} = \bar{y}_C$$
  

$$\Rightarrow \beta_0 = \frac{\bar{y}_A + \bar{y}_B + \bar{y}_C}{3}$$

Struktur. tényleg M = tengelymóhatás ( $\beta_0$ )  
 a szimmetria interakciókat is! (az invariáns az utasítás, hogy elv-e a  
 szimmetria megváltozása)  
 strchange → breakpoints(df\$elavultsok ~ 1)\$breakpoints[2]

A seasonális megmutatja, hogy adott periódus eltér-e a trendtől  
 tér el az átlagtól / trendtől ⇒ Multipl. modell  
 Morf. átlagok szimmetria trendet (- vagy /) → aggregate(trend ~ Month, data, FUN=mean) →  
 → szimmetria (ostani a mean(trend) - el) - az átlag 1 (multipl. modell, add. -nál a szimmetria  
 ⇒ Hasonlóan / hasonlóan kapunk seasonális eltérést (Trend + 1 tag)

Time Series: ts(df\$elavultsok, start=c(2011,1), frequency=12) → Ravi  
 ↳ plot()

decompose(Time Series, type="additive"/"multiplicative")  
 ↳ plot() \$trend/seasonal  

$$\alpha = \frac{2}{n+1}, n = \frac{2}{\alpha} - 1$$

centralized MA: forecast → ma(df\$elavultsok, order=12)  
 non-centralized MA: 200 → rollmean(df\$elavultsok, 2=12, fill=NA)

Exponential MA: pracma → movavg(df\$elavultsok, n=9, type="e")  
 ↳  $\hat{y}_t = \alpha y_t + (1-\alpha)\hat{y}_{t-1}$ ,  $\hat{y}_1 = y_1$  ( $\alpha$ : mérték, hogy mennyire figyelünk az utolsó  
 megfigyelésre)

Minimális négyzetek  

$$\min_{\{g_t\}} \sum_{t=1}^T (y_t - g_t)^2 + \lambda \sum_{t=2}^T ((g_{t+1} - g_t) - (g_t - g_{t-1}))^2$$

mFilter → hpfilter(df\$elavultsok, freq=100, type="lambda")  
 RW  $x_1 = u_1$ ,  $x_t = x_{t-1} + u_t = \sum_{i=1}^t u_i$ ,  $E(x_t) = 0$ ,  $\text{Var}(x_t) = t \cdot \sigma^2$

RWD:  $x_1 = \delta + u_1$ ,  $x_t = \delta + x_{t-1} + u_t$ ,  $E(x_t) = t \cdot \delta$   
 ARIMA(p,d,q)  
 sta ⇒ d=0 Ilc

ADF:  $y_t = \delta + \gamma_t + u_t$   
 $\Delta y_t = \delta + (\gamma_t - \gamma_{t-1}) + u_t$   
 $H_0$ : egyenlőség  
 $H_1$ : trend



# Sarima SARIMA(p,d,q)(P,D,Q)s

- ACF kék s-vél => } szazonális => D=1
- PACF — n — => } diff
- Meg mindig kék => P=1, Q=1 (PACF) (ACF)
- A D-vél diff. felt. időszaka ARIMA

PR: SARIMA(1,1,1)(0,1,0,12)

- arima(df, order = c(1,1,1), seasonal = list(order = c(0,1,0), period = 12))

- lintest -> bgtest(resid(model) ~ 1, order = 13)

Kam's regresszió: csak leltörölgező a tapasztalat, valószínűsítendő egyrészt a folyamat => A stacioner időszaka rögzíti tapasztalatot kell nézni.

Hivélygys: szabály: az eredeti regresszióban a DW test értéke kisebb, mint az R<sup>2</sup>, akkor az ált. kam's regresszió jó.

- lintest -> dwtest(rwul2 ~ rwul22)

=> Többváltozós időszakkmodell csak stacioner időszaka

VAR(p) (szűkebbéteként nagy p => zagyos becslés)

- Több változó => amikor tartozik egyenlet az endogén; ami hatással van az end. vlt.-ra, de maga inkább a modellen kívül határozódik meg, az exogén

- df-ts = ts(df, start = c(1969), frequency = 4)

- tseries -> lapply(df-ts[, 2:3], adf.test)

(stacioner időszaka kellene!) & pss.test

- vars -> VARselect(df-ts-stac) => milyen p-t mond?

- vars -> VAR(df-ts-stac, p=2, type="B")

- libratory vizsgálat a kúlon:

- hiba = as.data.frame(resid(varmodell))

- lapply(hiba, function(x) { bgtest(x ~ 1, order = 5) })

- Egysétes test (Portmanteau) (ha H<sub>0</sub> igaz, akkor kúlon-kúlon is igaz)

- vars -> serial.test(varmodell, lags.p.t=5, type="PT.asymptotic")

H<sub>0</sub>: minden modelltag együttesen felel meg

Def: X időszaka Granger okos Y-t, ha X valószínűsíti a jövőbeni Y értékeit.

Wald-F próbák (ha VAR(1) van, akkor az ed. par. t- próbák)

$$F(1,10) = \frac{X_1^2/1}{X_{10}^2/10} = \frac{Z^2}{\frac{Z^2}{10}} = 10$$

- aad -> wald.test()

b = coef(varmodell\$varresult\$d-Fidesz)

Sigma = vcov(varmodell\$varresult\$d-Fidesz)

Terms = c(3,6)

H<sub>0</sub>: β-2 együttesen 0-z => Fgyorsító: NEM Granger-okos a Fidesz

Impulzusváltás: adott változóban bekövetkező szórásnövekedés: hogyan reagál a többi változóban

- plot(imp(modell, impulse="d-Fo", n.ahead=10, ortho=FALSE))

(Cholesky mátrix sorrendűségére vonatkozik => GVAR)

d-Fo növekedés hogyan hat a többi változóra (alább 95% konfidencia)

Becslési variancia decomp (FEVD): az előzőekbeni varianciajuttatás mértéke rejtett lehet megmagyarázni a modellen kívüli változók.

Pl.: a Fidesz becslési varianciájának 7,5%-át tudjuk megmagyarázni a folyamatok birtokában.

- vars -> fevd(modell, n.ahead=8)

=> sorrendűség!

frequency Connectedness ->

genFEVD(modell, n.ahead=8)

=> nem sorrendűség!



Kointegráció & VECM = 5 fővel és háttérben hűtőszigetelés is modellezhető vele

• Engle-Granger teszt (2 változó):  $x_t = x_{t-1} + u_t$ ;  $y_t = \gamma_0 + \gamma_1 x_t + v_t$   
 $\Rightarrow x_t \sim I(1)$ ;  $y_t - y_{t-1} = \gamma_0 + \gamma_1 x_t + v_t - \gamma_0 - \gamma_1 x_{t-1} - v_{t-1} = \gamma_1(x_t - x_{t-1}) + (v_t - v_{t-1})$

$\Rightarrow y_t \sim I(1) \Rightarrow x_t, y_t$  kointegráltak, azaz  $\exists$  lin. kombináció, ami stationer-e?  
 (teszt: kointegráció regn. mátrixára. Stationer-e?)

•  $\Delta x_t = C + Bx_{t-1} + \sum_{i=1}^{k-1} A_i \Delta x_{t-i} + u_t$   $\rightarrow$  Mann's regresszióval NEH  
 Hibuzoméró = kointegráció regresszió mérése

• Nagy késleltetés javára a VAR select  $\Rightarrow$  Valreg. életpéldák a variancia

• tsDyn  $\rightarrow$  VECM (df, lag=1, r=1, include="const", estim="ML")  
 Nem diff. ell.  $\rightarrow$  VAR re'  $\rightarrow$  rank(B)  $\rightarrow$  Johansen teszt

• Johansen teszt:  $r = \text{rank}(B) \rightarrow$  sajátértékek és a kointegráció B sajátértékei  
 $H_0: r=0, H_1: r>0 \rightarrow$  jobboldali  
 $H_0: r \leq 1, H_1: r>0 \rightarrow$  2 db ide'sor esetén  $r \leq 2-1$  (különb  $\exists B^{-1}$ ...)  
 $\vdots$   
 $H_0: r \leq 2-1, H_1: r>2-1 \rightarrow \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{2-1} \geq 0$  sajátértékek  $\chi^2$  eloszlás

• urca  $\rightarrow$  ca.jo (df, type="eigen"/"trace", ecdet="const", spec="longrun")  
 $\rightarrow$  summary(.)  $\rightarrow$  több dimenziós ts  $\rightarrow$  ts(df[,2:3], start=c(1990,01,01), frequency=)

• frequencyConnectedness  $\rightarrow$  genFEVD(vec2var(zaitest, r=5))

• irf ugyancsak  $\rightarrow$  ca.jo(...)  $\rightarrow$  VECM-ben  $r = \text{rank}(B)$   
 ARMA stat  $\Leftrightarrow$  kar polinom gyökei:  $u < 1$ , késleltet. operátor  $1.1 > 1$

ARIMAX esetén

• forecast  $\rightarrow$  Arima(BF\$X, order=c(2,1,0), xreg=as.matrix(BF[,4:6]), include.constant=T)

Késleltetés adat lineáris interpolációval:  $\bullet$  euro = na.approx(euro)

Előrejelzés forecast cronagbol:  $\bullet$  pr = forecast(model, h=10)

4. táblázat: ha logaritmusok:  $\bullet$  pr\$x = exp(pr\$X); pr\$mean = exp(pr\$mean)

Albra:  $\bullet$  Time = length(ferran)  $\rightarrow$  plot(pr, xlim=c(Time-100, Time+10), ylim=c(420, 540))

statikus: csak való's adatok  
 dinamikus: becült értékek (is)  $\rightarrow$  karl. operátor gyökei: abs(polyroot(c(1-model\$phi)))

VECM 2 változóval értelmezés: ECT  $\rightarrow$  arányul 1 ide'sor alatt az

egyre'gyi elmozdulásról hány egyre'get dolgoz ki az ATS (ATS célváltozó)

$\rightarrow$  Menekítse gyorsan igazodni a DEM-hez  $\rightarrow$  0,69  $\rightarrow$  0,69 egyre'get arányul dolgoz

$\Rightarrow 1/0,69 \approx 1,45 \rightarrow 1,5$  nap alatt be'adogozza az ATS az egyre'gyi elmozdulást

$\Rightarrow$  Csak 2 változóval értelmezni lehet!